



# Construindo um ensemble de CNNs para classificação de imagens de lesões de pele


---

Classificação multiclasse de imagens dermatoscópicas

# Autores

Pedro Lucas Silva Haga Torres

Roberta Barbosa Oliveira



# Introdução

---

# Caracterização do problema

- O câncer de pele é um dos tipos de câncer com maior incidência no Brasil [1]:
  - Podendo ser dividido em duas categorias: melanoma e não melanoma.
- O melanoma é a forma mais agressiva de câncer de pele, devido aos seus altos níveis de metástase;
- Existe um grande interesse mundial no desenvolvimento de sistemas de diagnóstico auxiliado por computador para processamento e análise de imagens de lesões de pele [2-4]:
  - Objetivando-se auxiliar a tomada de decisão dos dermatologistas.

# Caracterização do problema

- Imagens dermatoscópicas são adquiridas a partir de técnicas não invasivas:
  - Vêm sendo amplamente utilizadas na literatura [6];
  - São adquiridas por meio de um dispositivo dermatoscópico que permite uma visualização mais detalhada dos padrões da lesão na superfície da pele;
  - Estudos anteriores demonstraram que métodos computacionais podem fornecer resultados adequados para a identificação de lesões de pele em imagem [7].
- Dentre as várias abordagens clínicas que utilizam imagens dermatoscópicas, a regra ABCD (Assimetria, Borda, Cor e estruturas Diferenciais) tem sido muito aplicada para extrair características para o diagnóstico automático (Abbas et al., 2011).

# Caracterização do problema

- Algoritmos de aprendizagem de máquina (AM) se destacam na resolução de problemas envolvendo reconhecimento de padrões:
  - Entretanto, esses algoritmos necessitam de um grande volume de dados para alcançar uma solução satisfatória e generalizável.
- Em especial, arquiteturas de redes neurais convolucionais (CNN) são muito utilizadas em tarefas envolvendo imagens, dada sua capacidade de segmentação e reconhecimento de padrões [8];
- O International [Skin Imaging Collaboration \(ISIC\)](#) é um esforço internacional para aprimorar o diagnóstico de melanoma:
  - Em 2019 eles propuseram o desafio de [classificar imagens dermatoscópicas em 9 classes diferentes](#):
    - Melanoma, nevo melanocítico, carcinoma basocelular, ceratose actínica, ceratose seborreica, dermatofibroma, lesão vascular e carcinoma de células escamosas, além de uma 9ª classe representando imagens que não pertencem a nenhuma das classes anteriores.

# Metodologia

---

# Base de dados

- Foi utilizada a base de dados de treinamento disponibilizada pelo ISIC [9-11], que consiste de mais de 25 mil imagens dermatoscópicas de lesões de pele:

Diagnóstico	Número de amostras	Percentual do total
Melanoma	4522	17.85%
Nevo melanocítico	12875	50.83%
Carcinoma basocelular	3323	13.12%
Ceratose actínica	867	3.42%
Ceratose seborreica	2624	10.36%
Dermatofibroma	239	0.94%
Lesão vascular	253	1.00%
Carcinoma espinocelular	628	2.48%
N.D.A.	0	0.00%
<b>Total</b>	<b>25331</b>	<b>100.00%</b>




# Base de dados


- Como é possível ver, a base está desbalanceada;
- Uma forma de se lidar com o desbalanceamento se dá pelo o uso de *data augmentation* [12]:
  - Pode-se aumentar o número de imagens que não pertencem a classe de nevo melanocítico;
  - Porém, o uso demasiado dessa técnica pode levar a uma baixa capacidade de generalização.
- Uma segunda estratégia para lidar com o desbalanceamento é utilizar diferentes pesos para cada uma das classes durante o cálculo da função de perda da rede [13]:
  - Utilizou-se a seguinte equação para calcular o peso das classes:

$$peso_{classe} = \frac{total_{imagens}}{num_{classes} * num_{amostras}}$$


- Está se estudando como lidar com a 9ª classe (N.D.A.)




(a)



(b)



(c)




(d)




(e)



(f)



(g)

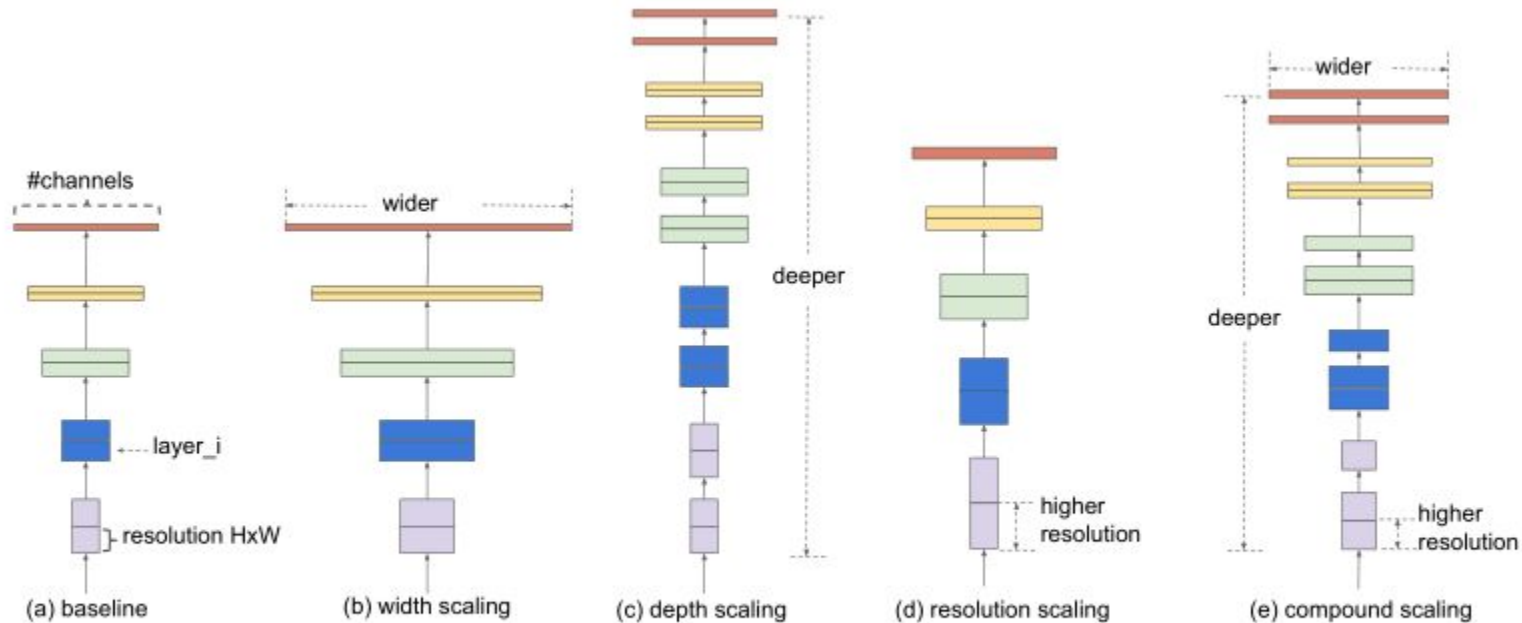


(h)

Exemplos de imagens dermatoscópicas: (a) melanoma, (b) nevo melanocítico, (c) carcinoma basocelular, (d) ceratose actínica, (e) ceratose seborreica, (f) dermatofibroma, (g) lesão vascular e (h) carcinoma espinocelular. Retiradas de [9-11].


# Metodologia: Projeto de pesquisa do PIBIC

- Neste trabalho, se propõe o uso de uma arquitetura baseada no *ensemble* homogêneo de redes EfficientNet [14], utilizando diferentes conjuntos de transformações de *data augmentation* para treinar essas redes;
- **Ensemble:** conjunto de dois ou mais classificadores cujas decisões individuais são combinadas de alguma forma para gerar uma predição mais robusta [15];
- **Data augmentation:** método artificial para aumentar a quantidade de dados disponíveis para o conjunto de treinamento [12]:
  - No caso de imagens, utilizam-se transformações das imagens já disponíveis, como: rotação, alterações nos parâmetros de cor (como brilho, saturação e matiz), entre outros.



**Figure 2. Model Scaling.** (a) is a baseline network example; (b)-(d) are conventional scaling that only increases one dimension of network width, depth, or resolution. (e) is our proposed compound scaling method that uniformly scales all three dimensions with a fixed ratio.








Fonte: M. Tan e Q. V. Le [14].



Fonte: M. Tan e Q. V. Le [14].


# Metodologia

- Aplicou-se o algoritmo Shades of Gray [16] para garantir a consistência de cores entre todas as imagens:



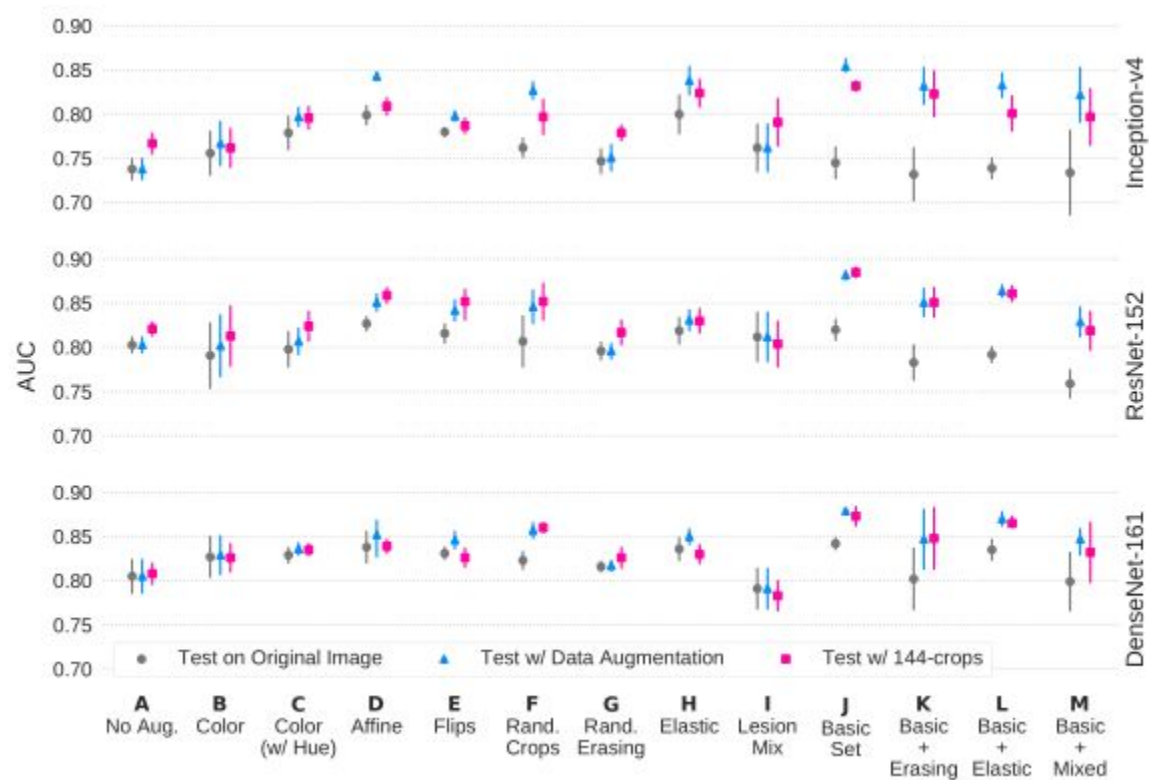
# Metodologia

- As transformações de *data augmentation* foram feitas somente no conjunto de treinamento, de maneira aleatória;
- Conforme proposta por Perez et al. [18]:
  1. Cortes aleatórios;
  2. *Affine*;
  3. Inversão horizontal e/ou vertical;
  4. Alterações nos parâmetros de saturação, contraste e brilho.



Fonte: Perez, C. Vasconcelos, S. Avila, and E. Valle [18].





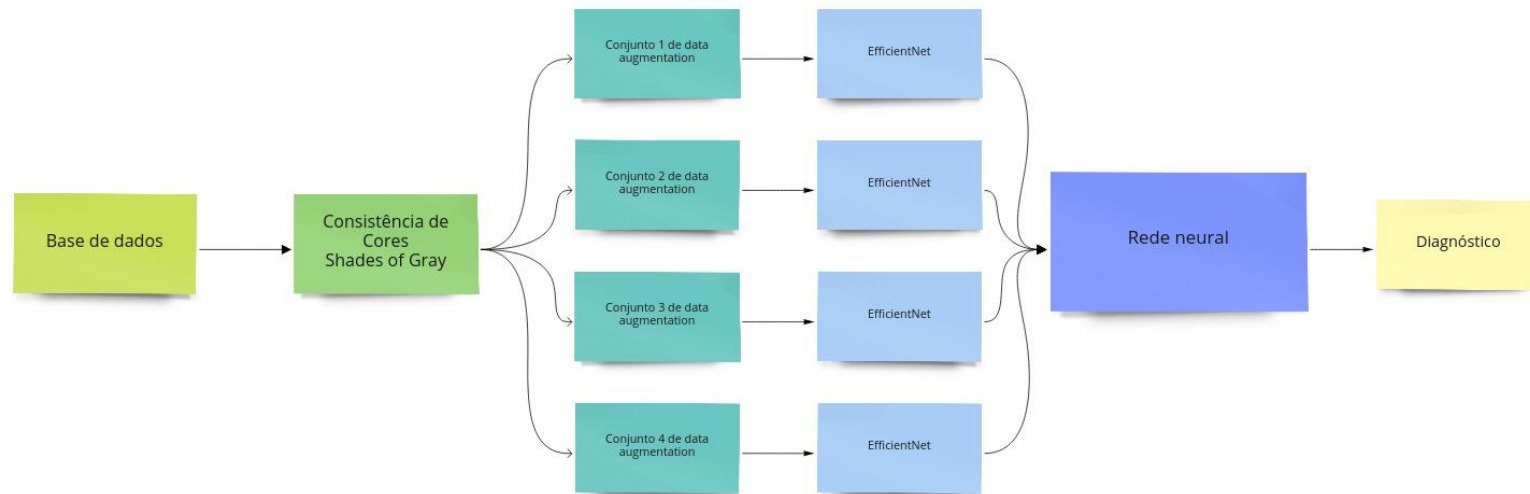
Fonte: Perez, C. Vasconcelos, S. Avila, and E. Valle [18].



# Metodologia: Projeto de pesquisa (FSI)

- Foram avaliadas as performances de classificação de dois otimizadores: SGD com gradiente acelerado de Nesterov [19] e Adam [20]. Esses otimizadores são complementares:
  - O Adam converge para uma solução rapidamente e a qualidade da solução é satisfatória:
    - Entretanto, ele pode ter problemas com alguns conjuntos de dados [21].
  - O SGD converge mais lentamente, entretanto a qualidade de sua solução é superior.
- Ambos foram treinados e avaliados sobre o mesmo conjunto de dados:
  - Isso é, as mesmas imagens originais somadas as mesmas imagens geradas pela técnica de *data augmentation*.
- E treinados sobre a arquitetura B2 da EfficientNet (dadas as limitações de hardware disponível).

# Visão geral




# Resultados

---

# Resultados de treinamento - perda (loss) da rede




SGD + Nesterov




Adam

# Resultados de treinamento - acurácia




SGD + Nesterov




Adam

# Resultados de treinamento - Macro F1-score

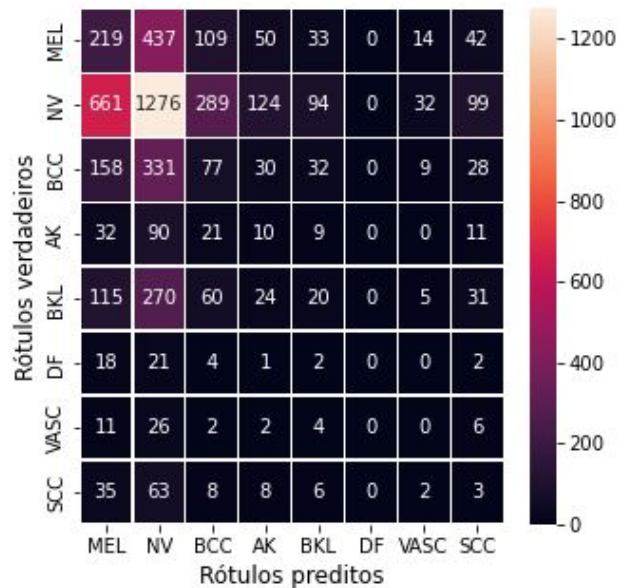


SGD + Nesterov




Adam

# Resultados de validação - matriz de confusão




SGD + Nesterov

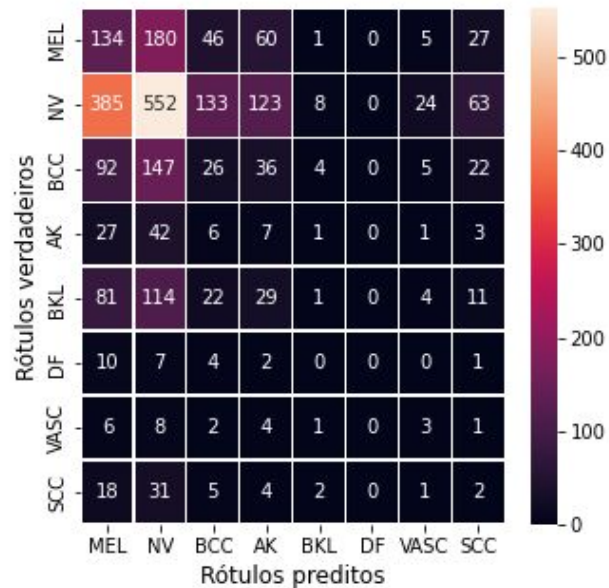


Adam

# Resultados de teste - matriz de confusão



SGD + Nesterov



Adam



# Resultados resumidos de validação e teste

Média aritmética entre as classes:

Métrica	SGD + Nesterov		Adam	
	Validação	Teste	Validação	Teste
Revocação	12,66%	12,16%	12,39%	12,98%
Especificidade	87,47%	87,58%	87,45%	87,84%
Precisão	12,67%	12,62%	12,30%	12,03%
F1-score	12,67%	12,12%	12,34%	12,49%
Acurácia	82,91%	82,91%	82,14%	82,15%

# Conclusão

---

# Conclusão

- Métricas de avaliação bastante próximas;
- Entretanto, o comportamento da curva de perda do modelo treinado com otimizador SGD + Nesterov é mais próxima do desejável:
  - Converge mais rápido e para uma solução melhor.
- Dessa forma, para o treinamento dos demais modelos a compor o *ensemble* usar-se-á SGD + Nesterov.

# Referências bibliográficas

- [1] Instituto Nacional de Câncer José Alencar Gomes da Silva, Estimativa 2020: incidência de câncer no Brasil. INCA, 2019. [Online]. Available: <https://www.inca.gov.br/publicacoes/livros/estimativa-2020-incidencia-de-cancer-no-brasil>
- [2] A. Mahbod, G. Schaefer, I. Ellinger, R. Ecker, A. Pitiot, and C. Wang, “Fusing fine-tuned deep features for skin lesion classification,” *Computerized Medical Imaging and Graphics*, vol. 71, pp. 19– 29, 2019. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S089561118306050>
- [3] M. S. Ali, M. S. Miah, J. Haque, M. M. Rahman, and M. K. Islam, “An enhanced technique of skin cancer classification using deep convolutional neural network with transfer learning models,” *Machine Learning with Applications*, vol. 5, p. 100036, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2666827021000177>
- [4] I. Iqbal, M. Younus, K. Walayat, M. U. Kakar, and J. Ma, “Automated multi-class classification of skin lesions through deep convolutional neural network with dermoscopic images,” *Computerized Medical Imaging and Graphics*, vol. 88, p. 101843, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0895611120301385>
- [5] M. E. Celebi, T. Mendonca, and J. S. Marques, *Dermoscopy image analysis*. CRC Press, 2015, vol. 10.
- [6] Silveira, M., Nascimento, J. C., Marques, J. S., Marca, A. R. S., Mendonca, T., Yamauchi, S., Maeda, J., & Rozeira, J. (2009). Comparison of Segmentation Methods for Melanoma Diagnosis in Dermoscopy Images. *IEEE Journal of Selected Topics in Signal Processing*, 3, 35-45.
- [7] Abbas, Q., Fondón, I., & Rashid, M. (2011). Unsupervised skin lesions border detection via two-dimensional image analysis. *Computer Methods in Biomedicine*, 104, e1-e15.

# Referências bibliográficas

- [8] W. Wang, Y. Yang, X. Wang, W. Wang, and J. Li, “Development of convolutional neural network and its application in image classification: a survey,” *Optical Engineering*, vol. 58, no. 4, pp. 1 – 19, 2019. [Online]. Available: <https://doi.org/10.1117/1.OE.58.4.040901>
- [9] P. Tschandl, C. Rosendahl, and H. Kittler, “The ham10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions,” *Scientific data*, vol. 5, no. 1, pp. 1–9, 2018.
- [10] N. C. Codella, D. Gutman, M. E. Celebi, B. Helba, M. A. Marchetti, S. W. Dusza, A. Kalloo, K. Liopyris, N. Mishra, H. Kittler et al., “Skin lesion analysis toward melanoma detection: A challenge at the 2017 international symposium on biomedical imaging (isbi), hosted by the international skin imaging collaboration (isic),” in *2018 IEEE 15th international symposium on biomedical imaging (ISBI 2018)*. IEEE, 2018, pp. 168–172.
- [11] M. Combalia, N. C. Codella, V. Rotemberg, B. Helba, V. Vilaplana, O. Reiter, C. Carrera, A. Barreiro, A. C. Halpern, S. Puig et al., “Bcn20000: Dermoscopic lesions in the wild,” *arXiv preprint arXiv:1908.02288*, 2019.
- [12] C. Shorten and T. M. Khoshgoftaar, “A survey on image data augmentation for deep learning,” *Journal of Big Data*, vol. 6, no. 1, 2019, cited By :516. [Online]. Available: <https://doi.org/10.1186/s40537-019-0197-0>
- [13] J. M. Johnson and T. M. Khoshgoftaar, “Survey on deep learning with class imbalance,” *Journal of Big Data*, vol. 6, no. 1, pp. 1–54, 2019.
- [14] M. Tan and Q. V. Le, “Efficientnet: Rethinking model scaling for convolutional neural networks,” *CoRR*, vol. abs/1905.11946, 2019. [Online]. Available: <http://arxiv.org/abs/1905.11946>

# Referências bibliográficas

- [15] S. Russell and P. Norvig, Artificial Intelligence: A Modern Approach. Upper Saddle River, NJ, USA: Pearson, 2010, vol. 3, ch. 18, p. 748.
- [16] G. D. Finlayson and E. Trezzi, “Shades of gray and colour constancy,” Color and Imaging Conference, vol. 2004, no. 1, pp. 37–41, 2004. [Online]. Available: <https://www.ingentaconnect.com/content/ist/cic/2004/00002004/00000001/art00008>
- [17] C. Barata, M. E. Celebi, and J. S. Marques, “Improving dermoscopy image classification using color constancy,” IEEE Journal of Biomedical and Health Informatics, vol. 19, no. 3, pp. 1146–1152, 2015.
- [18] F. Perez, C. Vasconcelos, S. Avila, and E. Valle, “Data augmentation for skin lesion analysis,” in OR 2.0 Context-Aware Operating Theaters, Computer Assisted Robotic Endoscopy, Clinical Image-Based Procedures, and Skin Image Analysis. Springer, 2018, pp. 303–311.
- [19] Y. Nesterov, “A method for unconstrained convex minimization problem with the rate of convergence  $o(1/k^2)$ ,” Doklady AN USSR, vol. 269, pp. 543–547, 1983. [Online]. Available: <https://ci.nii.ac.jp/naid/20001173129/en/>
- [20] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization”. 2017.
- [21] A. C. Wilson, R. Roelofs, M. Stern, N. Srebro, and B. Recht, “The marginal value of adaptive gradient methods in machine learning,” 2018.